Московский Авиационный Институт
(Национальный Исследовательский Университет)
Институт № 8 информационных технологий и прикладной математики
Кафедра вычислительной математики и программирования

Лабораторная работа №5 по курсу
«Дискретный анализ»

алгоритм Укконена

Студент: Пермяков Никита Александрович
Группа: М80 – 208Б-19
Вариант: 2
Преподаватель: *Кухтичев Антон Алексеевич*
Оценка: _____
Дата: _____
Подпись: _____

Москва, 2020

Содержание

Постановка задачи

Необходимо реализовать алгоритм Укконена построения суффиксного дерева за линейное время.

Алфавит строк: строчные буквы латинского алфавита (т.е. от a до z).

Вариант 2: Поиск с использованием суффиксного массива. Найти в заранее известном тексте поступающие на вход образцы с использованием суффиксного массива.

Входные данные: текст располагается на первой строке, затем, до конца файла, следуют строки с образцами.

Выходные данные: для каждого образца, найденного в тексте, нужно распечатать строку, начинающуюся с последовательного номера этого образца и двоеточия, за которым, через запятую, нужно перечислить номера позиций, где встречается образец в порядке возрастания.

Метод и алгоритм решения

Каждый узел содержит итераторы, указывающие на начало и конец этой подстроки в тексте и суффиксную ссылку, указывающею на вершину с таким же суффиксом, только без первого символ. При отсутствии такой вершины – на корень. Также есть словарь с ребрами, выходящими из данной вершины. В дереве храним текст с терминальным символом в конце, по которому ищем, указатель на корень, переменную remainder, которая показывает, сколько суффиксов еще надо вставить. Указатель fake_node указывает на вершину, из которой необходимо создать суффиксную ссылку, если в данной фазе уже была вставлена вершина по правилу ```*Если ребро разделяется и вставляется новая вершина, и если это не первая вершина, созданная на текущем шаге, ранее вставленная вершина и новая вершина соединяются через специальный указатель, суффиксную ссылку*```, и сейчас оно используется вновь. Указатель current_node указывает на вершину, которое имеет ребро current_point, в котором мы сейчас находимся. current_lenght показывает на каком расстоянии от этой вершины мы находимся. Итеративно проходим по тексту для создания дерева. На каждой итерации начинается новая фаза и remainder увеличивается на 1. Далее пока все не вставленные суффиксы не вставлены в дерево выполняем цикл. Если в той вершине, в которой мы остановились еще нет ребра, начинающегося с первой буквы

обрабатываемого суффикса, то по правилу продолжений ```*current_node остается корнем. текущее ребро становится первым символом нового суффикса, который нужно вставить, т.е. b current_lenght уменьшается на 1*``` создаем новую вершину, которая будет листом.

Если это необходимо, создаем суффиксную ссылку.

Если в той вершине, в которой мы остановились, уже есть такое ребро, то нужно пройти вниз по ребрам на current_lenght и обновить current_node.

Если некоторый путь на этом ребре начинается со вставляемого символа, значит по правилу ```*В любой фазе, если правило продления применяется в продолжении суффикса, начинающего в позиции j, оно же и будет применяться во всех дальнейших продолжениях (от j+1 по i) до конца фазы.*``` нам ничего делать не надо, заканчиваем фазу, оставшиеся суффиксы будут добавлены неявно. Увеличиваем current_lenght на 1 (т.к. учитываем, что этот символ уже есть на данном пути), по необходимости строим суффисную ссылку. Если никакой путь не начинается со вставляемого символа, то нужно разделить ребро в этом месте, вставив 2 новых вершины – одну листовую и одну разделяющую ребро. Далее по необходимости добавляем суффиксную ссылку. Уменьшаем remainder на 1, если вставили суффикс в цикле. Если после всех этих действий current_node указывает на корень и current_lenght больше 0, то уменьшаем current_lenght на 1, а current_point устанавливаем на первый символ нового суффикса, который нужно вставить. Если current_node не корень, то переходим по суффиксной ссылке.

После конструирования дерева, строим суффиксный массив. В нем расположен вектор, в котором находятся начальные позиции суффиксов, и все эти суффиксы лексикографически упорядочены. Массив строим из дерева, выполняя обход в глубину.

Т.к. словарь, который находится в каждой вершине, это упорядоченный контейнер, то номера позиции после обхода в глубину будут также лексикографически упорядочены.

Поиск вхождений в массиве осуществляется с помощью бинарного поиска. В зависимости от того, лексикографически меньше или больше буква в паттерне и буква в тексте, границы поиска в массиве сужаются наполовину. В конце возвращается диапазон начальных позиций, в которых найдены вхождения.

Описание программы

main.cpp – файл с реализацией

Дневник отладки

1 – 2) Синтаксические ошибки компиляции

3 – 5) Неверное сложение, ошибки в перегрузке оператора, взятие копии числа, ошибки в логике вычислений

6-9) Переполнение представления числа

10 – 14) Ошибки в логике вычислений

15) Успешная попытка

16 - 17) Рефакторинг и оптимизация

Тестирование производительности

Тесты проводились 5 раз для каждой конфигурации, рассчитывалось среднее значение времени исполнения

(2, 3 колонка для кастомной и библиотечной версии соответственно).

M - мощность алфавита

1000 - длина случайного текста

[1,50) - диапазон возможной длины случайного паттерна

Таблица 1. Результаты тестов производительности

Test Config	**`TSuffixTree` [µs]**	**std::string::find [µs]**
10 000 строк, M = 6	**260746**	**508278**
100 000 строк, M = 6	**2389398**	**4404435**

1 000 000 строк, M = 6	**23955876**	**53444390**
10 000 строк, M = 26	**139460**	**204579**
100 000 строк, M = 26	**1650844**	**4175808**
1 000 000 строк, M = 26	**17571014**	**39477540**

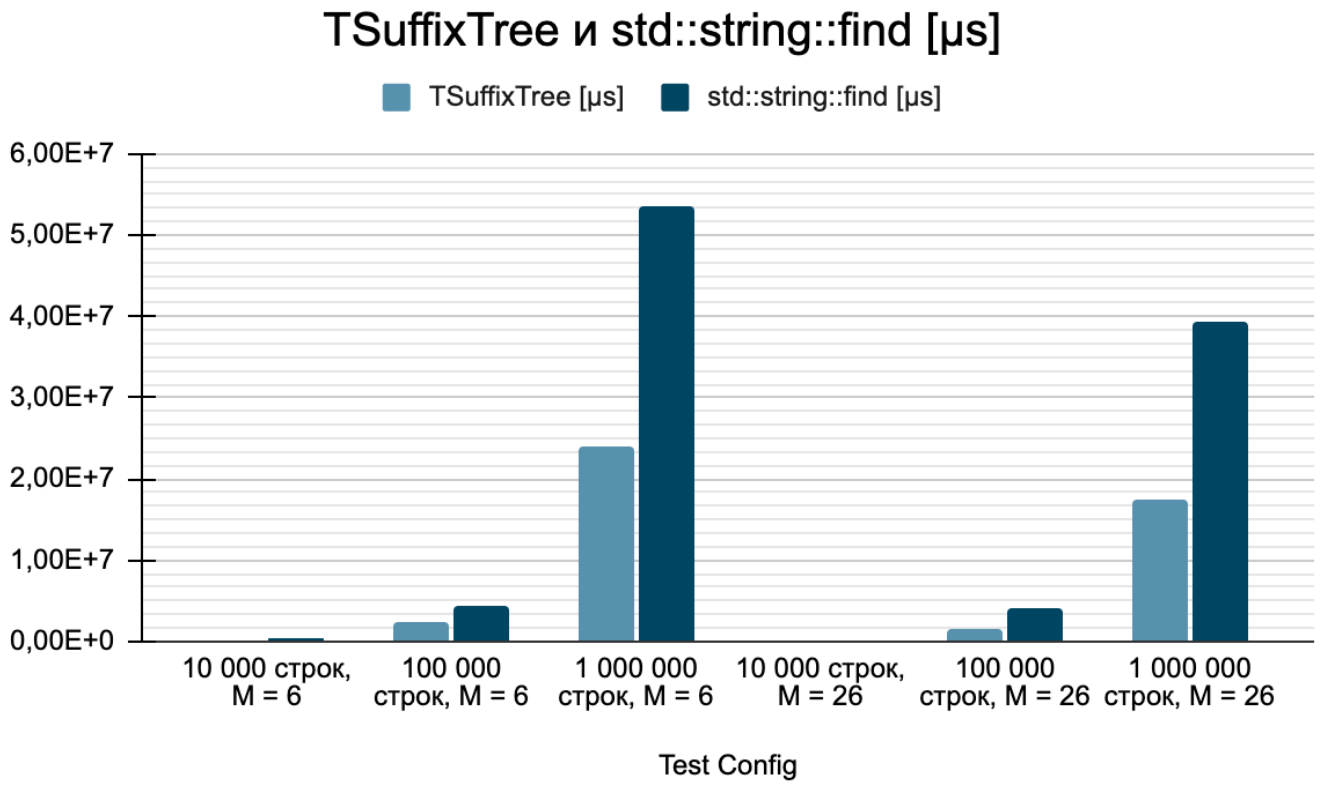

Вывод

В результате работы был реализован алгоритм Укконена и поиск с использованием суффиксного массива. Было проведено сравнение суффиксного дерева за линейное время с методом find типа данных string из Стандартной библиотеки C++.

Результаты тестов производительности доказали эффективность алгоритма Укконена по сравнению с методом find - состоящий из алгоритмом поиска Кнута - Морриса - Пратта.

Можно отметить следующие недостатки алгоритма Укконена:

- Размер суффиксного дерева сильно превосходит входные данные, поэтому при очень больших входных данных алгоритм Укконена

сталкивается с проблемой memory bottleneck problem (когда процессор в ограниченный промежуток времени требует больше памяти, чем доступно на это время).

- Для ответа на запрос о существовании перехода по текущему символу за O(1) необходимо хранить линейное количество информации от размера алфавита в каждой вершине. Поэтому, с увеличением мощности алфавита растет объем необходимой памяти. Можно сэкономить на памяти, храня в каждой вершине только те символы, по которым из неё есть переходы.
- Существуют кэш-эффективные алгоритмы, превосходящие алгоритм Укконена на современных процессорах. Cache-oblivious алгоритмы используют метод “Разделяй-и-властвуй”, в котором задача разбивается на маленькие задачи и подзадачи. В процессе разделения, у нас получаются небольшие подзадачи. В какой-то момент, эти подзадачи начинают помещаться в размер кэша
- Также алгоритм предполагает, что дерево полностью должно быть загружено в оперативную память.